

Titanic



Analiza danych o pasażerach Titanica

0 Danych

Dane o pasażerach Titanica

Zbiór danych zawiera informacje o pasażerach RMS Titanic, który zatonął 15 kwietnia 1912 roku po zderzeniu z górą lodową. Dane obejmują takie atrybuty jak klasa podróży, wiek, płeć, liczba rodzeństwa/małżonków na pokładzie, liczba rodziców/dzieci na pokładzie, cena biletu oraz miejsce zaokrętowania.

Zbiór zawiera także informację o tym, czy pasażer przeżył katastrofę.

Titanic przewoził ponad 2,200 osób, z czego ponad 1,500 zginęło, co czyni tę katastrofę jedną z najbardziej tragicznych w historii morskiej.

0 Danych

Kolumny:

- **pclass** - Klasa biletu
- **survived** - Czy pasażer przeżył katastrofę
- **name** - Imię i nazwisko pasażera
- **sex** - Płeć pasażera
- **age** - Wiek pasażera
- **sibsp** - Liczba rodzeństwa/małżonków na pokładzie
- **parch** - Liczba rodziców/dzieci na pokładzie
- **ticket** - Numer biletu
- **fare** - Cena biletu
- **cabin** - Numer kabiny
- **embarked** - Port, w którym pasażer wszedł na pokład (C = Cherbourg, Q = Queenstown, S = Southampton)
- **boat** - Numer łodzi ratunkowej
- **body** - Numer ciała (jeśli pasażer nie przeżył i ciało zostało odnalezione)
- **home.dest** - Miejsce docelowe

1. Przegląd i analiza danych dotyczących Titanica i jego pasażerów.

1.1 Wczytanie danych i przegląd losowych wartości.

1.1 Wczytanie danych i przegląd losowych wartości.

	pclass	survived	name	sex	age	sibsp	parch
701	3.0	0.0	Calic, Mr. Petar	male	17.0	0.0	0.0
994	3.0	0.0	Mardirosian, Mr. Sarkis	male	NaN	0.0	0.0
350	2.0	1.0	Brown, Miss. Edith Eileen	female	15.0	0.0	2.0
986	3.0	0.0	Maenpaa, Mr. Matti Alexanteri	male	22.0	0.0	0.0
409	2.0	0.0	Fox, Mr. Stanley Hubert	male	36.0	0.0	0.0
917	3.0	1.0	Karun, Mr. Franz	male	39.0	0.0	1.0

1.1 Wczytanie danych i przegląd losowych wartości.

	pclass	survived	name	sex	age	sibsp	parch
701	3.0	0.0	Calic, Mr. Petar	male	17.0	0.0	0.0
994	3.0	0.0	Mardirosian, Mr. Sarkis	male	NaN	0.0	0.0
350	2.0	1.0	Brown, Miss. Edith Eileen	female	15.0	0.0	2.0
986	3.0	0.0	Maenpaa, Mr. Matti Alexanteri	male	22.0	0.0	0.0
409	2.0	0.0	Fox, Mr. Stanley Hubert	male	36.0	0.0	0.0
917	3.0	1.0	Karun, Mr. Franz	male	39.0	0.0	1.0

	ticket	fare	cabin	embarked	boat	body	home.dest
701	315086	8.6625	NaN	S	NaN	NaN	NaN
994	2655	7.2292	F E46	C	NaN	NaN	NaN
350	29750	39.0000	NaN	S	14	NaN	Cape Town, South Africa / Seattle, WA
986	STON/O 2. 3101275	7.1250	NaN	S	NaN	NaN	NaN
409	229236	13.0000	NaN	S	NaN	236.0	Rochester, NY
917	349256	13.4167	NaN	C	15	NaN	NaN

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 1310 entries, 0 to 1309

Data columns (total 14 columns):

#	Column	Non-Null Count	Dtype
0	pclass	1309 non-null	float64
1	survived	1309 non-null	float64
2	name	1309 non-null	object
3	sex	1309 non-null	object
4	age	1046 non-null	float64
5	sibsp	1309 non-null	float64
6	parch	1309 non-null	float64
7	ticket	1309 non-null	object
8	fare	1308 non-null	float64
9	cabin	295 non-null	object
10	embarked	1307 non-null	object
11	boat	486 non-null	object
12	body	121 non-null	float64
13	home.dest	745 non-null	object

dtypes: float64(7), object(7)

memory usage: 143.4+ KB

Po wczytaniu danych mamy informację o 1310 wierszach i 14 kolumnach.

Zauważyć można, że w wierszu 1309, we wszystkich kolumnach są puste wartości, należy zatem usunąć ten wiersz przed przystąpieniem, do dalszej analizy.

Po przeglądzie losowych wartości widać, że istnieje wiele pustych wartości w niektórych kolumnach. W dalszej analizie, należy zastanowić się, czy brakujące wartości będą miały istotny wpływ na wyniki analizy i czy będzie potrzeba wypełnienia tych wartości.

Jeden z wierszy ma puste wartości we wszystkich kolumnach

Jeden z wierszy ma puste wartości we wszystkich kolumnach

[illegible]

Jeden z wierszy ma puste wartości we wszystkich kolumnach

	pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	embarked	boat
1309	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN

Usuwaam wiersz z pustymi wartościami.

1.2 Sprawdzenie wartości unikatowych.

1.2 Sprawdzenie wartości unikatowych.

	0
pclass	3
survived	2
name	1307
sex	2
age	98
sibsp	7
parch	8
ticket	929
fare	281
cabin	186
embarked	3
boat	27
body	121
home.dest	369

Krótkie spostrzeżenia o wartościach unikatowych:

- **pclass** - 3 klasy biletów (ilu pasażerów w każdej klasie)
- **survived** - 2 wartości oznaczające czy pasażer ocalał, czy nie(sprawdzić ilu ocalonych)
- **name** - 1307 nazwisk na 1309 rekordów (sprawdzić duplikaty)
- **sex** - 2 wartości oznaczające płeć (sprawdzić ile kobiet/mężczyzn)
- **age** - 98 wartości określających wiek (w losowych danych widać wiek podany jako ułamek, zamienić na liczby całkowite, ponownie sprawdzić wartości unikatowe)
- **sibsp** - 7 wartości dla liczby rodzeństwa/małżonków na pokładzie
- **parch** - 8 wartości dla rodziców/dzieci na pokładzie
- **ticket** - 929 wartości z numerem biletu (sprawdzić duplikaty, dlaczego występują)
- **fare** - 281 wartości z różną ceną biletu(sprawdzić od czego uzależniona cena)
- **cabin** - 186 numerów kabin
- **embarked** - 3 różne porty wejścia pasażerów na pokład
- **boat** - 27 numerów łodzi ratunkowych(jakieś zależności?)
- **body** - 121 wartości dla odnalezionych ciał ofiar katastrofy
- **home.dest** - 369 wartości dla celu podróży pasażerów(sprawdzić korelację ocalony cel podróży)

1.3 Przegląd danych statystycznych.

1.3 Przegląd danych statystycznych.

	pclass	survived	age	sibsp	parch	fare	bc
count	1309.000000	1309.000000	1046.000000	1309.000000	1309.000000	1308.000000	121.000000
mean	2.294882	0.381971	29.881135	0.498854	0.385027	33.295479	160.809000
std	0.837836	0.486055	14.413500	1.041658	0.865560	51.758668	97.696000
min	1.000000	0.000000	0.166700	0.000000	0.000000	0.000000	1.000000
25%	2.000000	0.000000	21.000000	0.000000	0.000000	7.895800	72.000000
50%	3.000000	0.000000	28.000000	0.000000	0.000000	14.454200	155.000000
75%	3.000000	1.000000	39.000000	1.000000	0.000000	31.275000	256.000000
max	3.000000	1.000000	80.000000	8.000000	9.000000	512.329200	328.000000

Mamy 7 kolumn numerycznych, przechowujących dane o klasie biletu, ocalałych, wieku, rodzeństwa/małżonków, rodziców/dzieci, cenie biletu, odnalezionym ciele ofiary.

Katastrofę przeżyło 38% pasażerów.

Najmłodszy z pasażerów miał mniej niż rok, najstarszy 80 lat, średni wiek to ok 30 lat.

49% pasażerów podróżowało z małżonkiem lub rodzeństwem.

38% pasażerów było rodzicami/dziećmi

Średnia cena biletu to 33. najtańszy bilet kosztował 0, najdroższy 512.

Odnaleziono 121 ciał.

2. Analiza brakujących wartości.

	0
pclass	0
survived	0
name	0
sex	0
age	263
sibsp	0
parch	0
ticket	0
fare	1
cabin	1014
embarked	2
boat	823
body	1188
home.dest	564

Brakujące dane:

- **age** 263 dane o wieku (naprawić średnią dla mężczyzn i kobiet?)
- **fare** 1 cena biletu (naprawić średnią ceną)
- **cabin** 1014 danych o numerze kabiny
- **embarked** 2 informacje o porcie wejścia pasażerów na pokład
- **boat** 823 numer łodzi ratunkowej, w której przebywał pasażer (sprawdzić brakujące wartości dla ocalałych pasażerów)
- **body** 1188 numer ciała
- **home.dst** 564 celu podróży.


3. Analiza poszczególnych danych.

PCLASS - ilość pasażerów w każdej klasie


PCLASS - ilość pasażerów w każdej klasie

count	
pclass	
1.0	323
2.0	277
3.0	709

Ilość pasażerów w danej klasie



Ilość pasażerów w danej klasie



Mamy tutaj 3 klasy, w których podróżowali pasażerowie.

W klasie 1 podróżowało 323 pasażerów, w klasie 2 podróżowało 277 pasażerów, w klasie 3 podróżowało 709 pasażerów.

SURVIVED - ilość ocalałych i ofiar

SURVIVED - ilość ocalałych i ofiar

	Ilość
Zginęło	809
Przeżyło	500

SURVIVED - ilość ocalałych i ofiar

Ilość	
Zginęło	809
Przeżyło	500

Katasrtofę przeżyło 500 pasażerów, zginęło 809 pasażerów.

SEX - ilość kobiet i mężczyzn wśród pasażerów, dane o ofiarach

SEX - ilość kobiet i mężczyzn wśród pasażerów, dane o ofiarach

	Ilość
Kobiet	466
Mężczyzn	843

SEX - ilość kobiet i mężczyzn wśród pasażerów, dane o ofiarach

	Ilość
Kobiet	466
Mężczyzn	843

Wśród pasażerów było 466 i 843 mężczyzn

SEX - ilość kobiet i mężczyzn wśród pasażerów, dane o ofiarach

	Ilość
Kobiet	466
Mężczyzn	843

Wśród pasażerów było 466 i 843 mężczyzn

	Kobiet	Mężczyzn
Zginęło	127	682
Przeżyło	339	161

SEX - ilość kobiet i mężczyzn wśród pasażerów, dane o ofiarach



	Ilość
Kobiet	466
Mężczyzn	843

Wśród pasażerów było 466 i 843 mężczyzn

	Kobiet	Mężczyzn
Zginęło	127	682
Przeżyło	339	161

Spośród 500 ocalonych, przeżyło 339 kobiet i 161 mężczyzn.

Procentowy udział Kobiet i Mężczyzn wśród ofiar





Ilość ocalonych pasażerów w każdej z klas

Ilość ocalonych pasażerów w każdej z klas

survived	
pclass	
1.0	200.0
2.0	119.0
3.0	181.0

Liczba ocalałych w każdej klasie według płci





Podróżujących w klasie 1 ocalało 200 z 323 osób, w klasie 2 ocalało 119 z 277 osób, w klasie 3 ocalało 181 z 709 osób

AGE - wiek pasażerów

AGE - wiek pasażerów

0	
0	29.0000
1	0.9167
2	2.0000
3	30.0000
4	25.0000
...	...
94	60.5000
95	74.0000
96	0.4167
97	11.5000
98	26.5000

99 rows × 1 columns

Ponieważ wiek nie jest podany w liczbach całkowitych, zaokrąglę go i zapiszę w nowej kolumnie

Ponieważ wiek nie jest podany w liczbach całkowitych, zaokrąglę go i zapiszę w nowej kolumnie

0	
0	29.0
1	1.0
2	2.0
3	30.0
4	25.0
...	...
69	66.0
70	9.0
71	0.0
72	10.0
73	74.0

74 rows × 1 columns

Ponieważ wiek nie jest podany w liczbach całkowitych, zaokrąglę go i zapiszę w nowej kolumnie

0	
0	29.0
1	1.0
2	2.0
3	30.0
4	25.0
...	...
69	66.0
70	9.0
71	0.0
72	10.0
73	74.0

74 rows × 1 columns


Po zaokrągleniu wieku pasażerów do liczb całkowitych, otrzymałem 74 wartości unikatowe. Dane zapisałem w nowej kolumnie - age_round.

Średni wiek pasażerów to blisko 30 lat, najmłodszy pasażer jest noworodkiem poniżej pół roku życia, najstarszy pasażer ma 80 lat.

Średni wiek pasażerów to blisko 30 lat, najmłodszy pasażer jest noworodkiem poniżej pół roku życia, najstarszy pasażer ma 80 lat.

age_round	
count	1046.000000
mean	29.870937
std	14.411571
min	0.000000
25%	21.000000
50%	28.000000
75%	39.000000
max	80.000000

Rozkład wieku pasażerów z podziałem na płeć



SIBSP - liczba rodzeństwa, małżonków na pokładzie

SIBSP - liczba rodzeństwa, małżonków na pokładzie

418 pasażerów było na pokładzie z rodzeństwem lub małżonkiem.

PARCH - liczba rodziców, dzieci na pokładzie

PARCH - liczba rodziców, dzieci na pokładzie

307 pasażerów było na pokładzie z rodzicem lub dzieckiem.

TICKET - numer biletu

TICKET - numer biletu

ticket	
count	1309
unique	929
top	CA. 2343
freq	11

TICKET - numer biletu

ticket	
count	1309
unique	929
top	CA. 2343
freq	11

Numery biletu mają 929 wartości unikatowych, na 1309 pozycji, należy sprawdzić duplikaty.

FARE - cena biletu

FARE - cena biletu

	count	mean	std	min	25%	50%	75%	max
pclass								
1.0	323.0	87.508992	80.447178	0.0	30.6958	60.0000	107.6625	512.3292
2.0	277.0	21.179196	13.607122	0.0	13.0000	15.0458	26.0000	73.5000
3.0	708.0	13.302889	11.494358	0.0	7.7500	8.0500	15.2458	69.5500


FARE - cena biletu

	count	mean	std	min	25%	50%	75%	max
pclass								
1.0	323.0	87.508992	80.447178	0.0	30.6958	60.0000	107.6625	512.3292
2.0	277.0	21.179196	13.607122	0.0	13.0000	15.0458	26.0000	73.5000
3.0	708.0	13.302889	11.494358	0.0	7.7500	8.0500	15.2458	69.5500


Cena biletu uzależniona była od klasy biletu. Średnia cena biletu dla klasy 1 to 87, dla klasy 2 to 13, dla klasy 3 to 11.

Najdroższy bilet miał cenę 512, najtańsze 0.

Rozkład cen biletów w zależności od klasy biletu




Rozkład cen biletów w zależności od klasy biletu



Bardzo duża rozpiętość cen biletów, zwłaszcza w klasie 1. Najwięcej wartości zarejestrowanych w okolicy 10 dla klasy 3.

Dla lepszego zobrazowania dla klas 1 i 2, wykres z ograniczonym zakresem

Dla lepszego zobrazowania dla klas 1 i 2, wykres z ograniczonym zakresem



CABIN - numer kabiny

CABIN - numer kabiny

	cabin
count	295
unique	186
top	C23 C25 C27
freq	6

CABIN - numer kabiny

	cabin
count	295
unique	186
top	C23 C25 C27
freq	6

Mamy informacje o 295 kabinach, które posiadają 186 wartości unikatowych.

EMBARKED - port wejścia na pokład

EMBARKED - port wejścia na pokład

count	
embarked	
S	914
C	270
Q	123

EMBARKED - port wejścia na pokład

count	
embarked	
S	914
C	270
Q	123

Mamy dane na temat 3 portów, w których pasażerowie wchodzili na pokład.

S = Southampton - 914 pasażerów

C = Cherbourg - 270 pasażerów

Q = Queenstown - 123 pasażerów

BOAT - numer łodzi ratunkowej

BOAT - numer łodzi ratunkowej

boat	
count	486
unique	27
top	13
freq	39

BOAT - numer łodzi ratunkowej

boat	
count	486
unique	27
top	13
freq	39

Mamy informacje o 27 unikatowych numerach łodzi ratunkowych.

BODY - numer ciała jeśli pasażer nie przeżył i ciało zostało odnalezione

BODY - numer ciała jeśli pasażer nie przeżył i ciało zostało odnalezione

0	
0	NaN
1	135.0
2	22.0
3	124.0
4	148.0
...	...
117	14.0
118	131.0
119	312.0
120	328.0
121	304.0

122 rows × 1 columns

BODY - numer ciała jeśli pasażer nie przeżył i ciało zostało odnalezione

0	
0	NaN
1	135.0
2	22.0
3	124.0
4	148.0
...	...
117	14.0
118	131.0
119	312.0
120	328.0
121	304.0

122 rows × 1 columns

Mamy informacje o 121 unikatowych numerach odnalezionych ciał.

HOME.DEST - miejsce docelowe podróżujących

10 ▾ entries per page

Search:

0 ▴ ▾

St Louis, MO
Montreal, PQ / Chesterville, ON
New York, NY
Hudson, NY
Belfast, NI
Bayside, Queens, NY
Montevideo, Uruguay
Paris, France
NaN
Hessle, Yorks

HOME.DEST - miejsce docelowe podróżujących

HOME.DEST - miejsce docelowe podróżujących

Mamy informacje o 370 unikatowych miejscach docelowych. Jednak po przeglądzie części rekordów, widać, że niektóre częściowo powtarzają się, poprzez podanie np. 2 miejsc docelowych (London/NY, itd.)

4. Transformacja danych.

Duplikaty

Duplikaty


	pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	embar
0	1.0	1.0	Allen, Miss. Elisabeth Walton	female	29.0000	0.0	0.0	24160	211.3375	B5	
1	1.0	1.0	Allison, Master. Hudson Trevor	male	0.9167	1.0	2.0	113781	151.5500	C22 C26	
2	1.0	0.0	Allison, Miss. Helen Loraine	female	2.0000	1.0	2.0	113781	151.5500	C22 C26	
3	1.0	0.0	Allison, Mr. Hudson Joshua Creighton	male	30.0000	1.0	2.0	113781	151.5500	C22 C26	

Duplikaty

	pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	embar
0	1.0	1.0	Allen, Miss. Elisabeth Walton	female	29.0000	0.0	0.0	24160	211.3375	B5	
1	1.0	1.0	Allison, Master. Hudson Trevor	male	0.9167	1.0	2.0	113781	151.5500	C22 C26	
2	1.0	0.0	Allison, Miss. Helen Loraine	female	2.0000	1.0	2.0	113781	151.5500	C22 C26	
3	1.0	0.0	Allison, Mr. Hudson Joshua Creighton	male	30.0000	1.0	2.0	113781	151.5500	C22 C26	

W numeracji biletów występują identyczne numery, jednak są przypisane do różnych osób o podobnych nazwiskach, co pozwala sądzić, że na jeden bilet przypisany był do kilku osób, np. rodziny.

	pclass	survived	name	sex	age_raw	sibsp	parch	ticket	fare	cabin	embarked
725	3.0	1.0	Connolly, Miss. Kate	female	22.0	0.0	0.0	370373	7.7500	NaN	
726	3.0	0.0	Connolly, Miss. Kate	female	30.0	0.0	0.0	330972	7.6292	NaN	
924	3.0	0.0	Kelly, Mr. James	male	34.5	0.0	0.0	330911	7.8292	NaN	
925	3.0	0.0	Kelly, Mr. James	male	44.0	0.0	0.0	363592	8.0500	NaN	



	pclass	survived	name	sex	age_raw	sibsp	parch	ticket	fare	cabin	embarked
725	3.0	1.0	Connolly, Miss. Kate	female	22.0	0.0	0.0	370373	7.7500	NaN	
726	3.0	0.0	Connolly, Miss. Kate	female	30.0	0.0	0.0	330972	7.6292	NaN	
924	3.0	0.0	Kelly, Mr. James	male	34.5	0.0	0.0	330911	7.8292	NaN	
925	3.0	0.0	Kelly, Mr. James	male	44.0	0.0	0.0	363592	8.0500	NaN	

Występują dwa identyczne nazwiska, jednak posiadają różne dane odnośnie wieku i numeru biletu. Można zatem stwierdzić, że nie są duplikatami.

Naprawa brakujących wartości

Naprawa brakujących wartości

AGE - Wypełnienie brakujących wartości wieku, średnią arytmetyczną dla kobiet i mężczyzn

Naprawa brakujących wartości

AGE - Wypełnienie brakujących wartości wieku, średnią arytmetyczną dla kobiet i mężczyzn

Średnia arytmetyczna dla kobiet 29.0

Naprawa brakujących wartości

AGE - Wypełnienie brakujących wartości wieku, średnią arytmetyczną dla kobiet i mężczyzn

Średnia arytmetyczna dla kobiet 29.0

Średnia arytmetyczna dla mężczyzn 31.0

Naprawa brakujących wartości

Naprawa brakujących wartości

FARE - Wypełnienie brakujących wartości ceny biletu, średnią arytmetyczną.

Naprawa brakujących wartości

FARE - Wypełnienie brakujących wartości ceny biletu, średnią arytmetyczną.

Brakujące wartości mamy dla 3 klasy

Naprawa brakujących wartości

FARE - Wypełnienie brakujących wartości ceny biletu, średnią arytmetyczną.

Brakujące wartości mamy dla 3 klasy

Średnia arytmetyczna w 3 klasie 13.3

Naprawa brakujących wartości

Naprawa brakujących wartości

BOAT - sprawdzenie pustych wartości o łodzi ratunkowej dla ocalałych pasażerów

Naprawa brakujących wartości

BOAT - sprawdzenie pustych wartości o łodzi ratunkowej dla ocalałych pasażerów

Empty Boat Count

0

23

Naprawa brakujących wartości

BOAT - sprawdzenie pustych wartości o łodzi ratunkowej dla ocalałych pasażerów

Empty Boat Count	
0	23

Występują puste wartości o nemarkach łodzi ratunkowych, w których byli ocaleni pasażerowie. Może to być wynikiem nieścisłości w zbieraniu danych lub mogło być wynikiem uratowania pasażerów w inny sposób.

5. Analiza relacji między zmiennymi

Klasa biletu, odsetek ocalałych.

Klasa biletu, odsetek ocalałych.




Klasa biletu, odsetek ocalałych.




Wykres pokazuje, że pasażerowie podróżujący w wyższej klasie, mieli większe szanse na przeżycie (1 - klasa najwyższa, 3 - klasa najniższa).

Cena biletu, klasa pasażerska.

Cena biletu, klasa pasażerska.



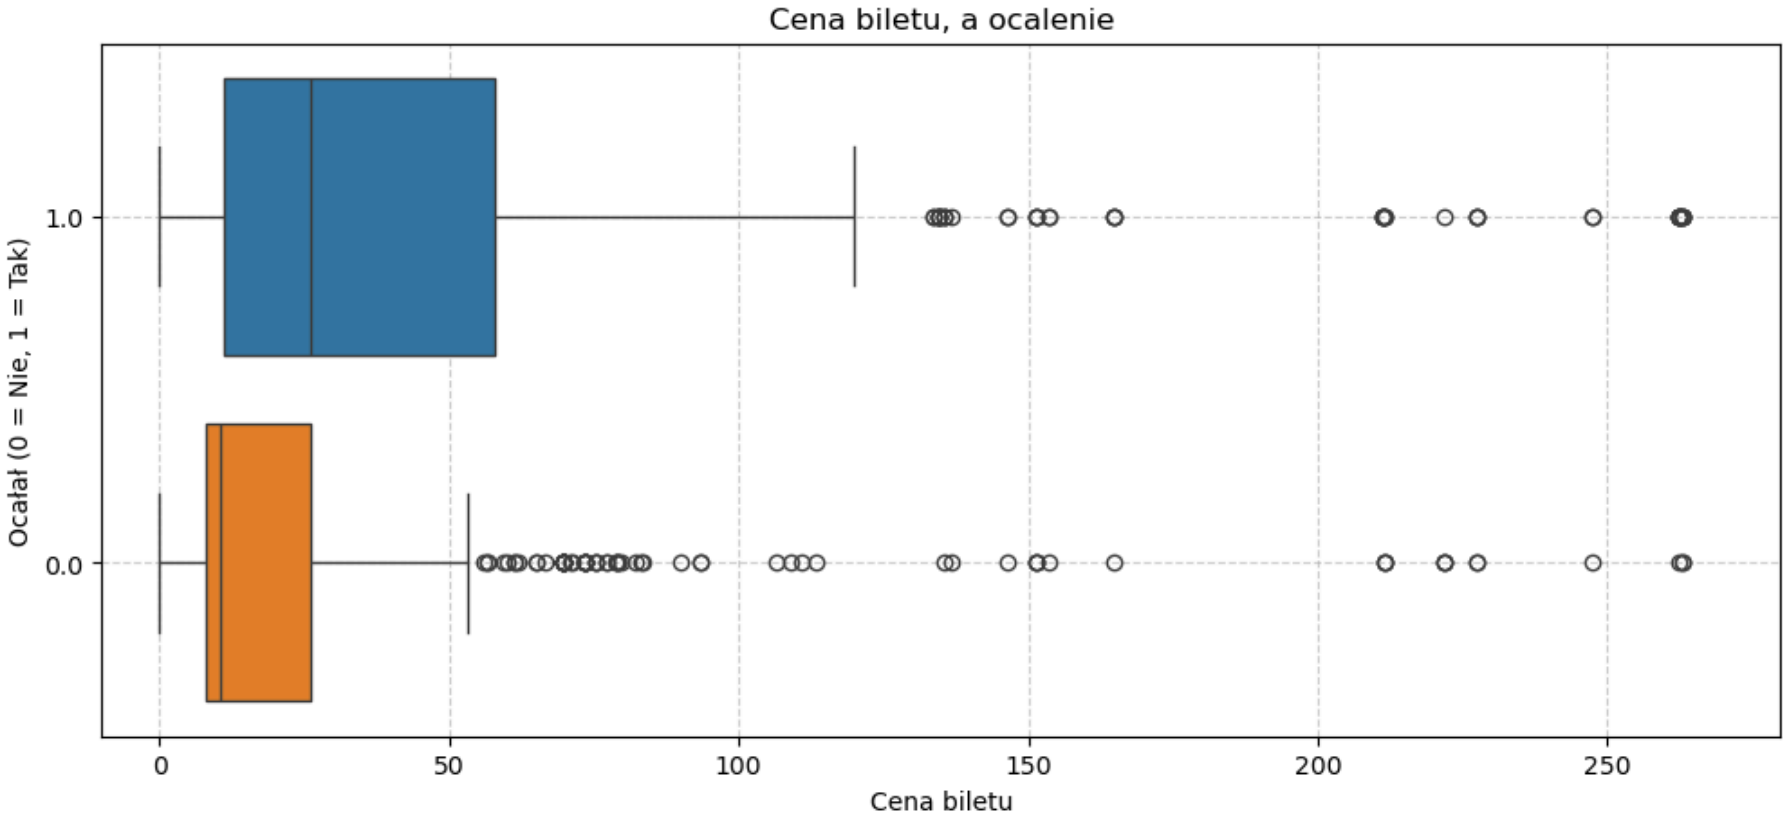
Cena biletu, klasa pasażerska.




Z wykresu wynika, że 75% wartości dla ceny biletu w klasie 3, jest poniżej 50% wartości cen biletu w klasie 2. Natomiast większość wartości cen biletów z klasy 3 i ponad 75% wartości cen biletów z klasy 2 jest poniżej 25% wartości cen biletów w klasie 1.

Cena biletu, ocalenie.

Cena biletu, ocalenie.



Cena biletu, ocalenie.



Wykres wykazuje, że cena jaką pasażer zapłacił za bilet, miała znaczny wpływ na to, czy pasażer ocalał, czy nie.

Jednak patrząc na wartości odstające mamy sporo zbliżonych cen biletu zarówno wśród pasażerów, którzy przeżyli, jak i zmarli.

Ocaleni, płeć, klasa.

Ocaleni, płeć, klasa.

<Figure size 1000x600 with 0 Axes>



Ocaleni, płeć, klasa.

<Figure size 1000x600 with 0 Axes>



Kobiety przeważają pod względem ocalenia. Im wyższa klasa pasażerska, tym większy odsetek kobier ocalał. Wśród mężczyzn największy odsetek ocalałych jest w klasie 1.

Łodzie ratunkowe, klasa pasażerska.

Łodzie ratunkowe, klasa pasażerska.

boat	
pclass	
1.0	201
2.0	112
3.0	173

Łodzie ratunkowe, klasa pasażerska.

boat	
pclass	
1.0	201
2.0	112
3.0	173

Na łodziach ratunkowych zarejestrowano 201 osób z klasy 1, 112osób z klasy 2 oraz 173 osoby z klasy 3.

Ciała ofiar z podziałem na klase.

Ciała ofiar z podziałem na klase.

body	
pclass	
1.0	35
2.0	31
3.0	55


Ciała ofiar z podziałem na klasę.

body	
pclass	
1.0	35
2.0	31
3.0	55


Odnaleziono 35 ciał spośród ofiar z 1 klasy, 31 ciał spośród ofiar z 2 klasy, 55 ciał spośród ofiar z 3 klasy.

Macierz korelacji dla kolumn numerycznych.

Macierz korelacji dla kolumn numerycznych.



Macierz korelacji dla kolumn numerycznych.



Widzimy korelację pomiędzy rodzinami(sibsp i parch). A także odwróconą korelację pomiędzy klasą pasażerską(pclass), a wiekiem(age), ceną biletu(fare) i ocalonymi(survived).

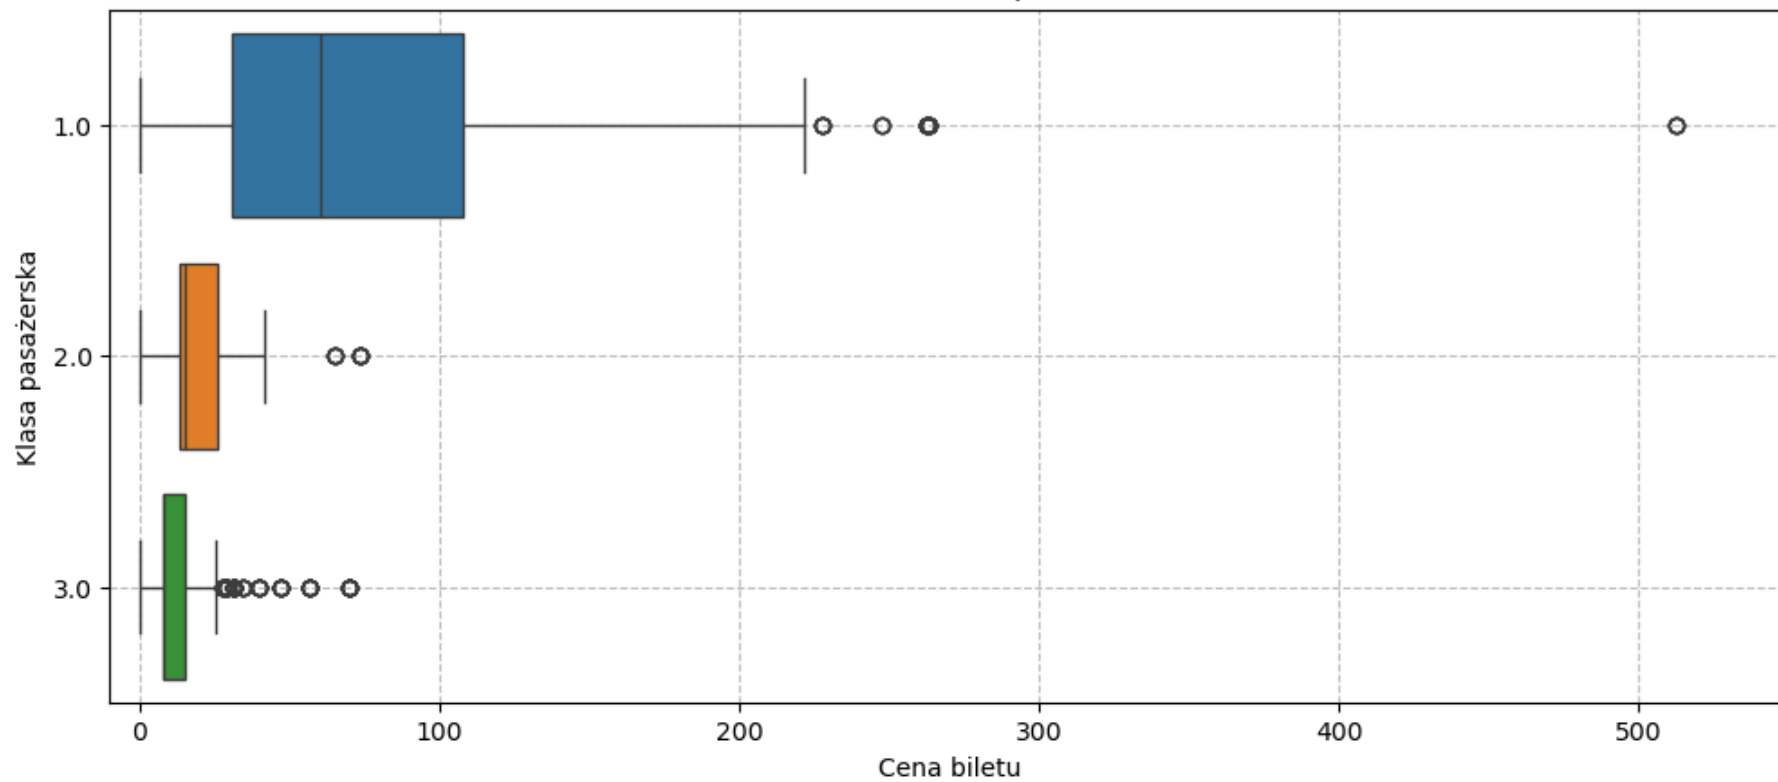
6. Wartości odstające.

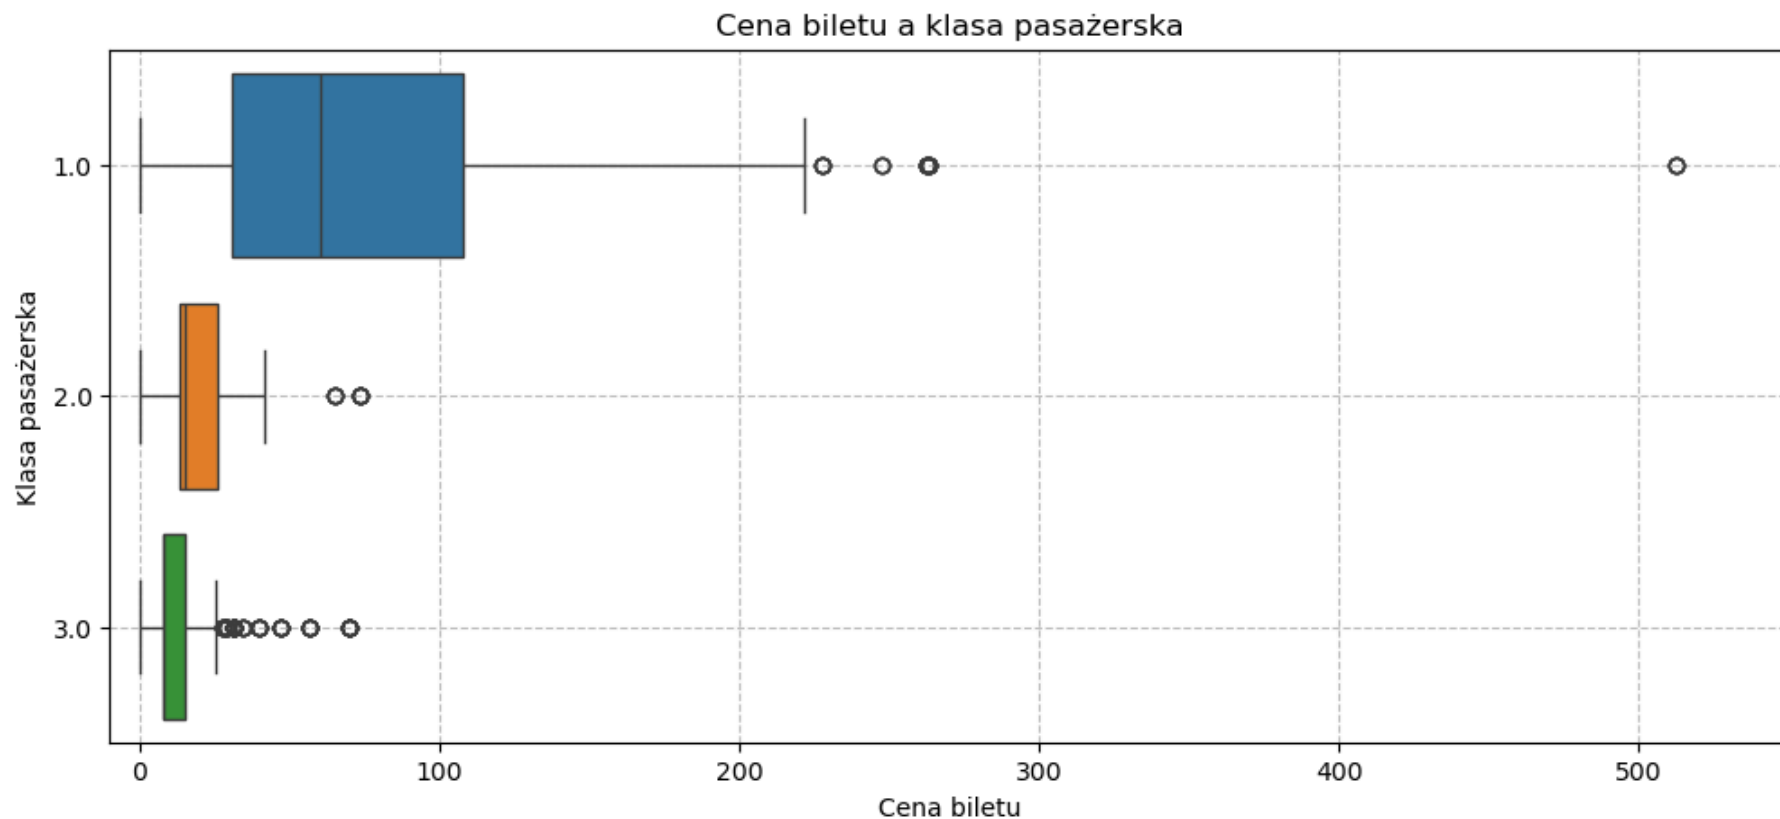
Cena biletu

Cena biletu

	count	mean	std	min	25%	50%	75%	max
pclass								
1.0	323.0	87.508992	80.447178	0.0	30.6958	60.0000	107.6625	512.3292
2.0	277.0	21.179196	13.607122	0.0	13.0000	15.0458	26.0000	73.5000
3.0	709.0	13.302885	11.486238	0.0	7.7500	8.0500	15.2458	69.5500

Cena biletu a klasa pasažerska






Wartości odstające dla cen biletów największą rozpiętość mają w klasie 1: w przybliżeniu od 220 do 520, w klasie 2 od 40 do 75, w klasie 3 od 25 do 70

Wiek


Wiek

age	
count	1309.000000
mean	29.978610
std	12.889776
min	0.000000
25%	22.000000
50%	30.000000
75%	35.000000
max	80.000000

Boxplot dla wieku pasażerów Titanica



Boxplot dla wieku pasażerów Titanica




Dane o wieku posiadają wartości odstające zarówno przy wartościach minimalnych - poniżej 2 lat, jak i maksymalnych - powyżej 53 lata.

Liczba rodzeństwa, małżonków na pokładzie


Liczba rodzeństwa, małżonków na pokładzie

	sibsp
count	1309.000000
mean	0.498854
std	1.041658
min	0.000000
25%	0.000000
50%	0.000000
75%	1.000000
max	8.000000

Boxplot dla liczby rodzeństwa, małżonków na pokładzie



Boxplot dla liczby rodzeństwa, małżonków na pokładzie




75% obserwacji miało 1 członka rodziny na pokładzie, wartości odstające było sięgały 8 członków rodziny.

Liczba rodziców, dzieci na pokładzie.


Liczba rodziców, dzieci na pokładzie.

parch	
count	1309.000000
mean	0.385027
std	0.865560
min	0.000000
25%	0.000000
50%	0.000000
75%	0.000000
max	9.000000

Boxplot dla liczby rodziców, dzieci na pokładzie



Boxplot dla liczby rodziców, dzieci na pokładzie



75% obserwacji nie miało żadnego członka rodziny na pokładzie. Wartości odstające sięgały 9 członków rodziny.

Podsumowanie

Liczebność i zakres danych:

Analizowany zbiór obejmuje 1310 pasażerów i 14 atrybutów, takich jak klasa podróży, wiek, płeć, liczba członków rodziny na pokładzie, cena biletu, miejsce zaokrętowania, numer kabiny, łodzi ratunkowej, ciała oraz cel podróży.

Przeżywalność:

Katastrofę przeżyło 38% pasażerów (500 osób), z czego zdecydowaną większość stanowiły kobiety (339 kobiet vs. 161 mężczyzn).

Klasa podróży:

Pasażerowie 1 klasy mieli najwyższy odsetek przeżycia (200 z 323 osób), w 2 klasie przeżyło 119 z 277 osób, w 3 klasie – 181 z 709 osób. Im wyższa klasa, tym większa szansa na przeżycie.

Płeć:

Na pokładzie było 466 kobiet i 843 mężczyzn. Kobiety miały zdecydowanie większą szansę na przeżycie niż mężczyźni.

Wiek:

Średni wiek pasażerów wynosił ok. 30 lat, najmłodszy pasażer miał mniej niż rok, najstarszy 80 lat. Wiek nie miał jednoznacznego wpływu na przeżycie, ale dzieci i kobiety były częściej ratowane.

Rodzina na pokładzie:

49% pasażerów podróżowało z rodzeństwem lub małżonkiem, 38% z rodzicem lub dzieckiem. Większe rodziny były rzadkością – wartości odstające sięgały 8-9 członków rodziny.

Cena biletu:

Średnia cena biletu to 33 jednostki walutowe, przy czym w 1 klasie średnio 87, w 2 klasie 21, w 3 klasie 13. Cena biletu silnie zależała od klasy i była powiązana z szansą przeżycia.

Port zaokrętowania:

Najwięcej pasażerów wsiadło w Southampton (914), następnie Cherbourg (270) i Queenstown (123).

Braki danych:

Najwięcej brakujących wartości dotyczyło numerów kabin (1014), wieku (263), celu podróży (564), numerów łodzi ratunkowych (823) i ciał (1188). Braki w wieku i cenie biletu można uzupełnić średnimi wartościami dla płci/klasy.

Duplikaty:

Występowały powtarzające się numery biletów, ale były przypisane do różnych osób (np. rodziny).

Wartości odstające:

Dotyczyły głównie cen biletów (zwłaszcza w 1 klasie) oraz liczby członków rodziny na pokładzie.

Korelacje:

Silna zależność między klasą podróży, ceną biletu a przeżyciem. Wysoka korelacja między liczbą rodzeństwa a liczbą rodziców/dzieci na pokładzie. Odwrócona korelacja między klasą a wiekiem, ceną biletu i przeżyciem.

Analiza potwierdza, że klasa podróży, płeć, cena biletu i port zaokrętowania były kluczowymi czynnikami wpływającymi na szanse przeżycia katastrofy Titanica.

